

Lojistik Regresyon

Lojistik regresyon (logistic regression) sınıflandırma (classification) için kullanılan bir makine öğrenmesi algoritmasıdır.

- Email: spam / spam değil
- Resim: kedi / köpek
- Röntgen: iyi huylu / kötü huylu

$$x \rightarrow \text{Loj. Reg.} \rightarrow y \quad y \in \{0, 1\}$$

Lojistik Regresyon

Lineer Regresyon

Sürekli (Continuous) bağımlı değişken

- Sınav notu
- Tümör boyutu
- Senelik gider
- Aylık gelir

Lojistik Regresyon

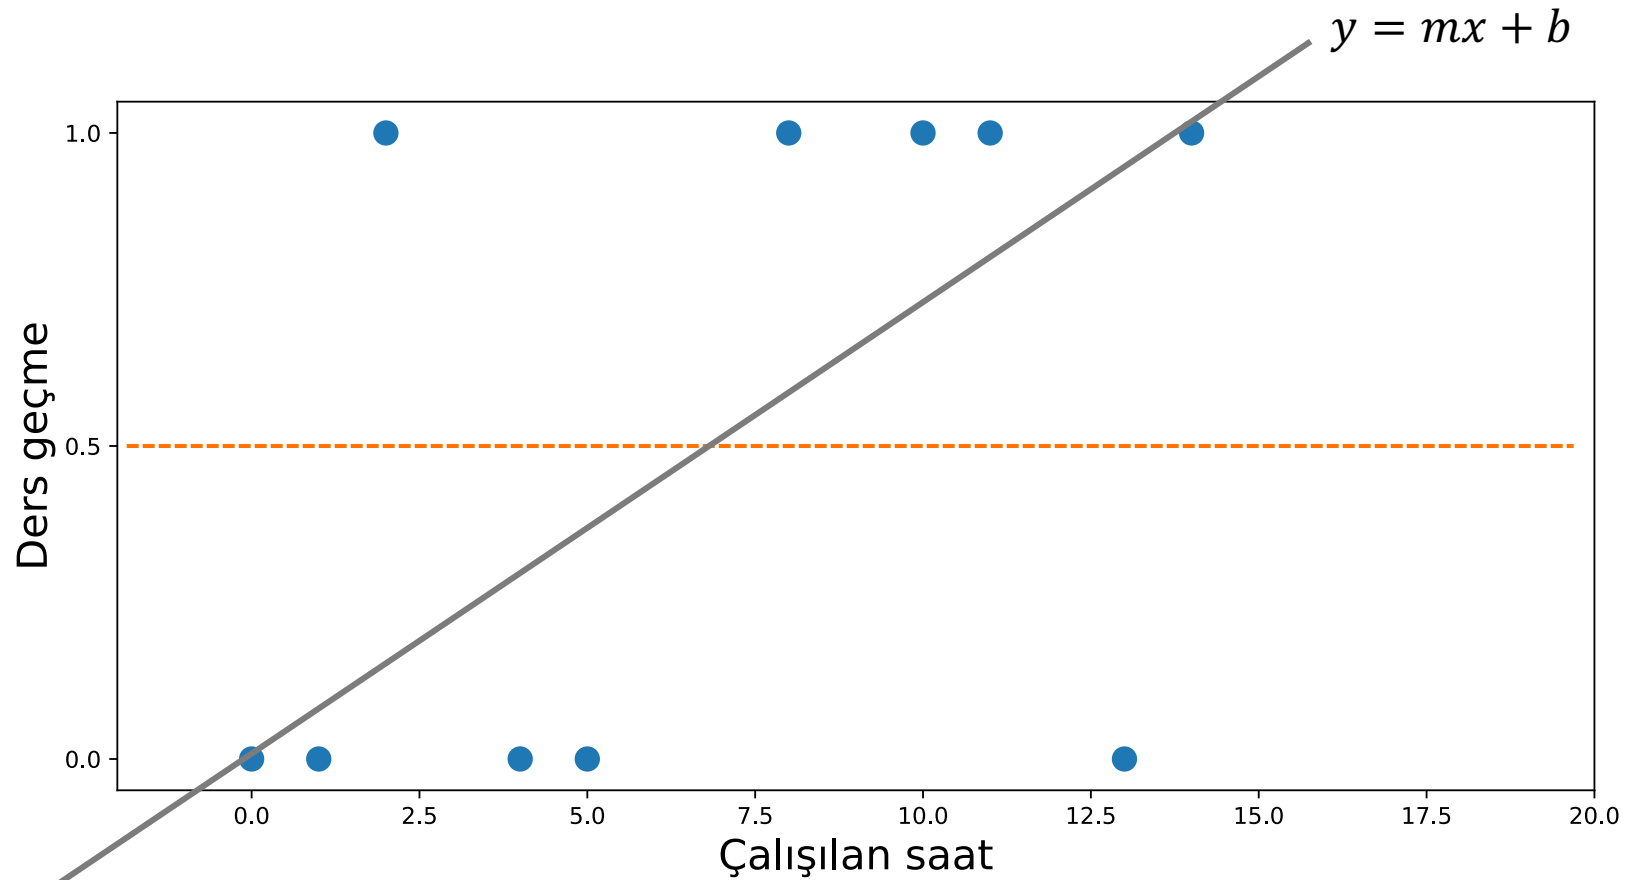
Kategorik (Categorical) bağımlı değişken

- Dersten geçme / kalma
- İyi huylu / kötü huylu
- Büyük / küçük
- Kredi onayı / reddi

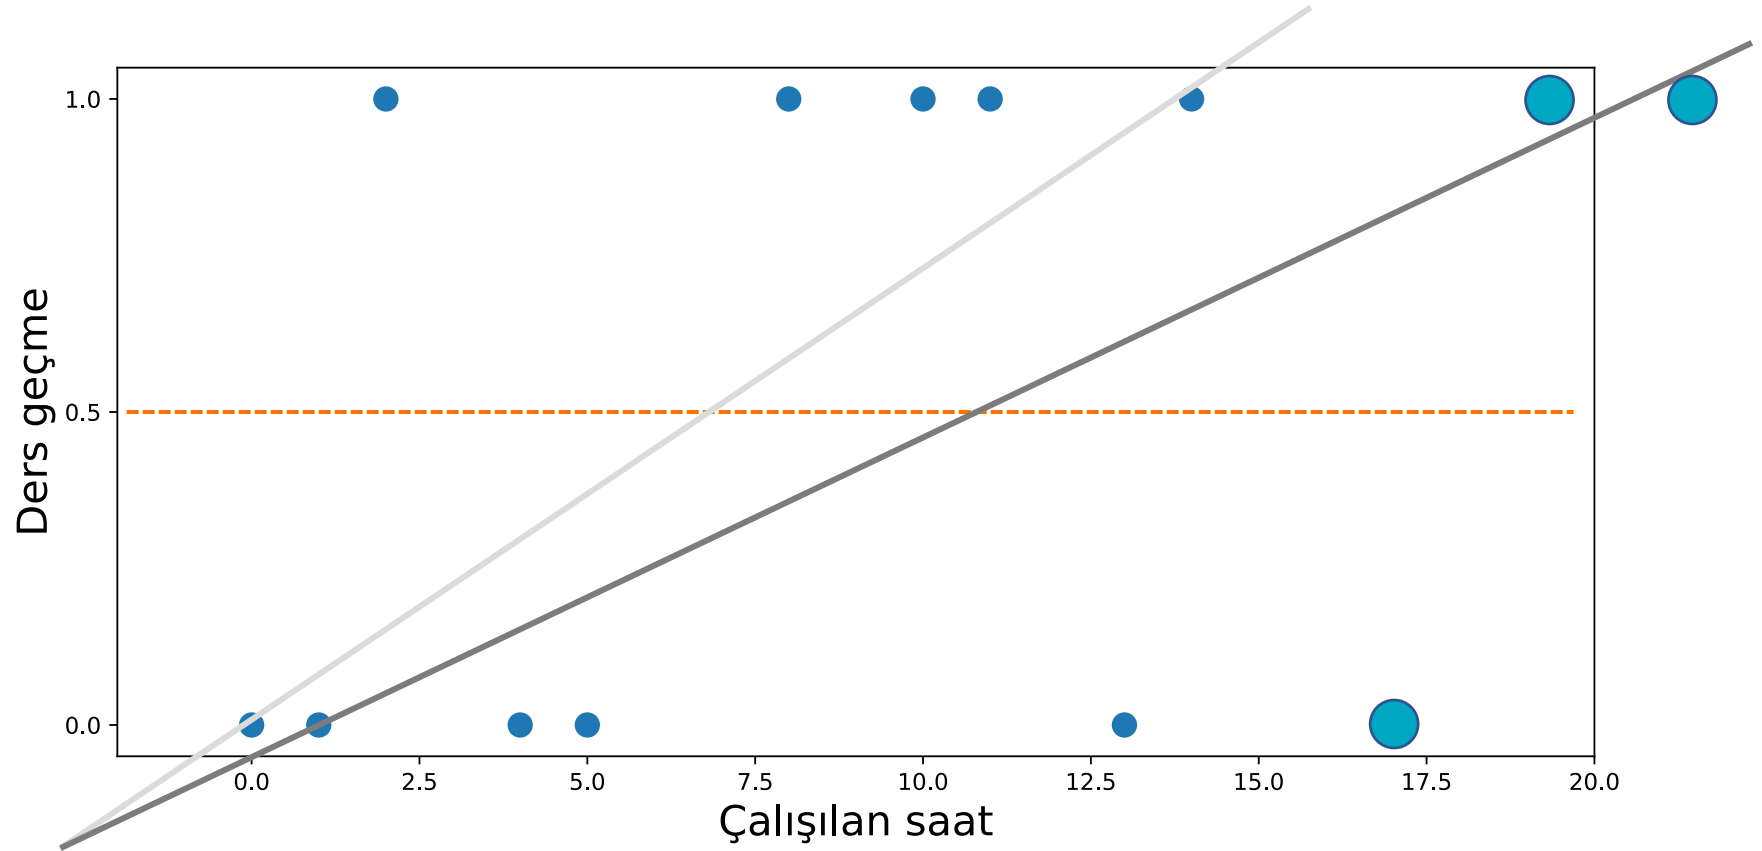
$$x \rightarrow \text{Lin.Reg.} \rightarrow y \quad y \in \mathbb{R}$$

$$x \rightarrow \text{Loj.Reg.} \rightarrow y \quad y \in \{0, 1\}$$

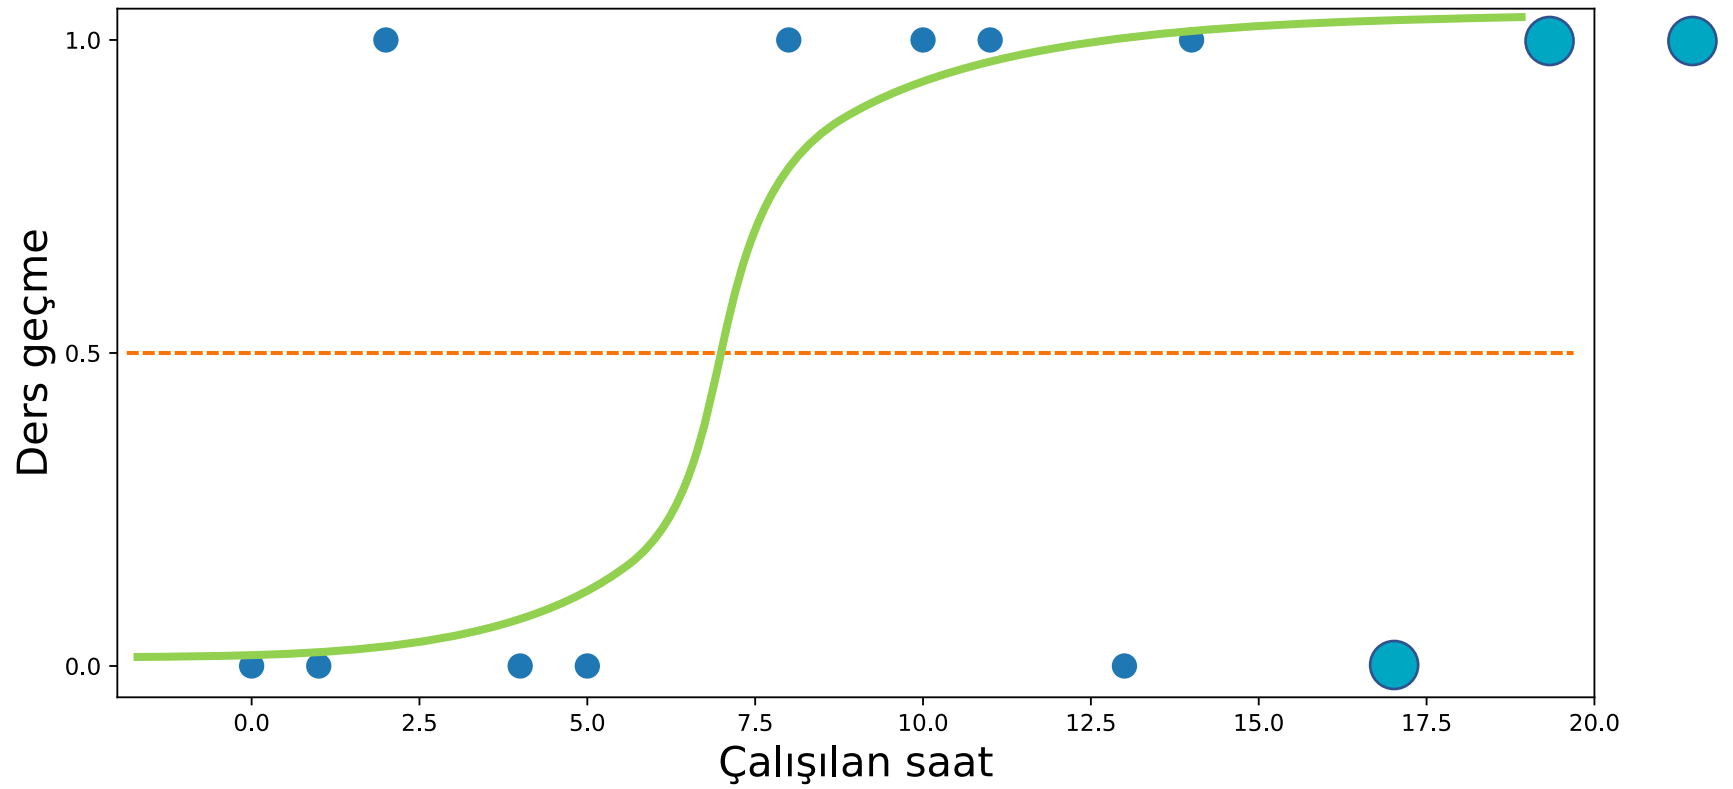
Lojistik Regresyon



Lojistik Regresyon



Lojistik Regresyon



Lojistik Regresyon

Lineer Regresyon: $h_{\theta}(x) = \theta^T x$

Lojistic Regresyon: $0 \leq y \leq 1$


$$0 \leq f(h_{\theta}(x)) \leq 1 \Rightarrow f = ?$$

i. $f(-\infty) \approx 0$

ii. $f(\infty) \approx 1$

Sigmoid (Logistic) Fonksiyonu

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$





Loj. Reg. Hata (Cost) Fonksiyonu

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

$$Hata(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)), & \text{eğer } y = 1 \\ -\log(1 - h_{\theta}(x)), & \text{eğer } y = 0 \end{cases}$$

Loj. Reg. Hata (Cost) Fonksiyonu

$$Hata(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)), & \text{eğer } y = 1 \\ -\log(1 - h_{\theta}(x)), & \text{eğer } y = 0 \end{cases}$$



Loj. Reg. Hata (Cost) Fonksiyonu

$$Hata(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)), & \text{eğer } y = 1 \\ -\log(1 - h_{\theta}(x)), & \text{eğer } y = 0 \end{cases}$$

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m Hata(h_{\theta}(x^{(i)}), y^{(i)})$$

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m -y^{(i)} \log h_{\theta}(x^{(i)}) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))$$

Loj. Reg. Dereceli Alçalma

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m -y^{(i)} \log h_{\theta}(x^{(i)}) - (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))$$

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$

Yakınsayana kadar tekrar et {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

}

Loj. Reg. Dereceli Alçalma

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$


Yakınsayana kadar tekrar et {

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$


}

Çoklu Sınıflandırma

İkili Sınıflandırma (Binary Classification)



Çoklu Sınıflandırma (Multi-class Classification)



Çoklu Sınıflandırma

Hepsine karşı birisi (One vs all classification)

